

Uso de IA Generativa:

Se permite el uso de estas herramientas para:

- Generar un código base, a partir de un diseño propio, sobre el cual aplicar optimizaciones.
- Generar gráficas y tablas a partir de los resultados, corregir ortografía y redacción, etc.
- Generar scripts que automaticen las pruebas a realizar.

NO se permite el uso de estas herramientas para:

- Automatizar la elección de una estrategia de optimización o el análisis del problema.
- Automatizar la interpretación de los resultados.

Laboratorio final

Cálculo de la distancia entre secuencias de ADN

El objetivo del laboratorio final es poner a prueba los conocimientos adquiridos durante el curso para la solución de un problema abierto. La evaluación del trabajo valorará aspectos como la estrategia empleada para paralelizar el problema y adaptarlo a la arquitectura de la GPU, la aplicación de conceptos teóricos adquiridos durante el curso, el uso correcto de recursos de la GPU (como memoria compartida, constante, operaciones shuffle, etc.) para lograr el mayor desempeño posible, la evaluación experimental de la propuesta utilizando las herramientas disponibles (medición del tiempo de ejecución, profilers, etc.) y la propuesta de mejoras guiada por la discusión de los resultados.

Introducción

Los avances en biología molecular y tecnologías de secuenciación de alto rendimiento han dado lugar a un crecimiento sin precedentes en la cantidad de datos genómicos disponibles para el análisis científico [1]. En particular, los estudios de genómica poblacional frecuentemente procesan conjuntos de datos que contienen miles de individuos y millones de marcadores genéticos, lo que crea importantes desafíos computacionales para el análisis a gran escala [2]. La información genética humana se representa comúnmente a través de polimorfismos de nucleótido único (SNP), que codifican variaciones en posiciones específicas del genoma. En organismos diploides, los SNP se almacenan típicamente como valores en $\{0, 1, 2\}$, que representan el número de alelos alternativos presentes en cada posición genómica. Una tarea común en genómica de poblaciones consiste en obtener una representación de datos genómicos que refleje con precisión la similitud genética entre individuos. En la práctica, los individuos genéticamente cercanos deberían aparecer próximos entre sí, mientras que las estructuras resultantes deberían preservar relaciones biológicamente significativas, como gradientes, patrones de mezcla genética y subestructuras poblacionales.

Este problema se puede dividir naturalmente en dos etapas. La primera consiste en calcular medidas de similitud o distancia entre individuos a partir de sus perfiles genómicos. La segunda utiliza estas distancias para construir una representación gráfica adecuada para tareas de análisis posteriores, como visualización, agrupamiento o reducción de dimensionalidad.

Sea $X = \{x_1, \dots, x_n\}$ un conjunto de muestras genómicas representadas como vectores SNP. Se construye una matriz de distancias $D \in R^{n \times n}$ como $D_{ij} = d(x_i, x_j)$, donde $d(\cdot, \cdot)$ es una métrica que satisface positividad, simetría y la desigualdad triangular. Entre las diferentes alternativas, se adopta la distancia euclidiana en este caso:

$$d(z, y) = \sqrt{\sum_{i=0}^m (z_i - y_i)^2}$$

donde m denota el número de SNP.

El cálculo directo de las distancias euclidianas por pares implica tres bucles anidados sobre individuos y SNP, lo que resulta en un rendimiento limitado debido a la baja intensidad aritmética y los patrones ineficientes de acceso a la memoria. Para superar estas limitaciones, varios trabajos reformulan el problema en términos de operaciones matriciales.

Sea $X \in \{0, 1, 2\}^{n \times m}$ la matriz genómica con n individuos y m SNP. La matriz de distancias euclidianas al cuadrado se puede expresar como:

$$D_{ij}^2 = \sum_{k=1}^m (X_{ik} - X_{jk})^2.$$

Utilizando la identidad:

$$d^2(x_i, x_j) = \|x_i\|^2 + \|x_j\|^2 - 2x_i x_j$$

la matriz de distancias completa se puede reformular como:

$$D^2 = \tilde{N} + \tilde{N}^T - 2XX^T, \quad (1)$$

donde $\tilde{N}_{ij} = \|x_i\|^2$ para todo j . Esta formulación transforma el cálculo dominante en un producto matriz-matriz, lo que permite el uso de BLAS [3] y rutinas de alto desempeño en GPU. En [4] se utiliza esta técnica para explotar los Tensor Cores de las GPU NVIDIA con aritmética INT8, aprovechando que los valores de SNP pertenecen a un dominio discreto muy pequeño.

Consigna

Se pide realizar una implementación en GPU, lo más eficiente posible, del cálculo de la matriz de distancias euclidianas.

La implementación debe funcionar para matrices de gran tamaño, y sacar partido de la particularidad de los datos de entrada (los SNP solo pueden tener tres valores). Algunas estrategias que se pueden seguir son las siguientes:

1. Codificar las matrices de entrada usando pocos bits para los valores 0, 1, y 2 (por ejemplo 00, 01, y 10), y utilizar operaciones binarias para realizar el producto matricial.
2. Utilizar tipos de datos como int4 o int8 para representar los SNPs y utilizar los Tensor Cores para acelerar el producto matricial usando la API wmma.
3. Utilizar la CPU para realizar parte del cómputo en paralelo con la GPU.

El producto XX^T es la operación que debería concentrar la mayor parte del costo computacional. La implementación de este kernel debe al menos explotar correctamente la memoria compartida para lograr que el acceso a memoria global sea coalesced y contener alguna optimización que saque partido del tipo de datos. También se debe tener en cuenta que la matriz D es simétrica, por lo que puede resultar conveniente aprovechar esto para reducir la cantidad de valores a calcular.

Se asumirá que la matriz X es divisible perfectamente en bloques de 32×32 , aunque esto no quiere decir que haya que utilizar dicho tamaño de bloque en la implementación. Otras asunciones pueden ser posibles dependiendo del caso.

La implementación de la operación debe ir acompañada de un informe donde se la describa en detalle y se justifiquen debidamente las decisiones y optimizaciones aplicadas. Entre otras cosas, se debe documentar la estrategia general de resolución, la asignación de trabajo a bloques, warps e hilos, y el uso de las distintas memorias de la GPU.

Es deseable que se desarrolle más de una versión y se puedan comparar experimentalmente, evaluando el impacto de las optimizaciones que se apliquen. La evaluación experimental debe contemplar distintos tamaños de matriz.

Como referencia, se debe utilizar punto flotante de simple precisión y comparar el desempeño de las variantes desarrolladas con una variante que utilice la operación *cublasSsyrk* de la biblioteca *cuBlas* para el producto XX^T . Para verificar el resultado compute $\|D - D_{cuBlas}\|_2$ utilizando las funciones *cublasSnrm2* y *cublasSaxpy*.

Entrega

- Se debe entregar un informe en PDF de **como máximo, 6 páginas** (sin contar carátula, referencias, anexos, etc.).
- El código fuente y archivos que permitan reproducir los resultados que figuran en el informe fácilmente.

Referencias

- [1] Reshmi Ramakrishnan, Ashitha Washington, S. Suveena, J. R. Rani, and Oommen V. Oommen. *From DNA to Big Data: NGS Technologies and Their Applications*, pages 459–482. Springer US, New York, NY, 2025. ISBN 978-1-0716-4690-8. doi: 10.1007/978-1-0716-4690-8_25. URL https://doi.org/10.1007/978-1-0716-4690-8_25.
- [2] The 1000 Genomes Project Consortium. A global reference for human genetic variation. *Nature*, 526: 68–74, 2015. doi: 10.1038/nature15393. URL <https://doi.org/10.1038/nature15393>.
- [3] BLAS Technical Forum. Basic linear algebra subprograms (blas). <https://www.netlib.org/blas/>, 2025. Accessed: 2025-10-31.
- [4] Hatem Ltaief, Rabab Alomairy, Qinglei Cao, Jie Ren, Lotfi Slim, Thorsten Kurth, Benedikt Dorschner, Salim Bougouffa, Rached Abdelkhalak, and David E. Keyes. Toward capturing genetic epistasis from multivariate genome-wide association studies using mixed-precision kernel ridge regression, 2024. URL <https://arxiv.org/abs/2409.01712>.