


Programación masivamente paralela en procesadores gráficos (GPUs)

E. Dufrechou, M. Freire, P. Ezzatti y M. Pedemonte



Clase 1

Introducción

Contenido

- **Motivación**
- **Curso de GPGPU**
- **Un poco de historia...**
- **El pipeline gráfico**
- **Tarjetas programables**
- **¿Por qué una arquitectura unificada?**
- **CUDA**
- **Comparación de la performance entre CPU vs GPU**


Motivación

Motivación

- **Utilización de hardware secundario para acelerar cálculos.**
- **Usar la tarjeta gráfica (GPU) para resolver problemas de propósito general (GPGPU).**
- **Se sustenta en el fuerte desarrollo tecnológico de las GPUs debido a la gran presión de la industria de los videojuegos.**
- **Surgimiento de lenguajes de programación de propósito general para programar las GPUs como CUDA, OpenCL y HIP.**

Motivación


Incremento significativo del poder de cómputo de las GPUs.



Motivación


Incremento significativo del poder de cómputo de las GPUs.

Theoretical GFLOP/s





Motivación

Incremento significativo en el ancho de banda de acceso a memoria



Motivación



Arquitectura intrínsecamente paralela (multiprocesadores)



Motivación

- **Es una plataforma ampliamente disponible.**
- **Hoy en día, una gran cantidad de laptops y desktops tienen disponible una GPU de Nvidia o AMD.**
- **Los celulares y tablets tiene disponibles GPUs (si bien no son exactamente iguales).**
- **Representan una tecnología que puede incorporarse tanto a un laptop como a una supercomputadora.**

Motivación



Motivación

- ¿Es una tecnología barata?
- H100 - PCIe card (Q4 2022):
 - Costo aproximado entre U\$S 25000 y U\$S 30000.
 - Tiene 14592 CUDA cores
 - Pico de performance en half precision 756.4 Tflops
 - Pico de performance en simple precisión 51.2 TFlops
 - Pico de performance en doble precisión 25.6 Tflops
 - 146.28 Gflops/W en simple
 - Ancho de banda de memoria de la GPU 2039 GB/s

Motivación

- ¿Es una tecnología barata?
- GeForce RTX 4090 (Q4 2022):
 - Costo aproximado U\$S 3500 en Newegg.com
 - Tiene 16384 CUDA cores
 - Pico de performance en half precision 73.1 Tflops (igual que en simple)
 - Pico de performance en simple precisión 73.1 TFlops
 - Pico de performance en doble precisión 1.142 Tflops (1/64 de simple)
 - 162.44 Gflops/W en simple
 - Ancho de banda de memoria de la GPU 1008 GB/s

Motivación

"Las GPUs han evolucionado hasta un punto en que muchas de las aplicaciones industriales actuales se ejecutan en ellas con niveles de rendimiento muy superiores a los que ofrecerían si se ejecutasen en sistemas multinúcleo. Las arquitecturas informáticas del futuro serán sistemas híbridos con GPUs compuestas por núcleos de procesamiento paralelo que trabajarán en colaboración con las CPUs multinúcleo".

Prof. Jack Dongarra

Director del Innovative Computing Laboratory

Universidad de Tennessee


Motivación

- Existe una apuesta fuerte de Nvidia por la adopción de GPUs para la computación de alta performance.
- Cientos de instituciones educativas enseñando GPGPU.
- Desarrollo de una comunidad científica y conferencias.
- Top 500:
 - Las 500 computadoras más poderosas del mundo.
 - <http://www.top500.org/>
 - Revisemos los 10 primeros puestos

Motivación

Top 500
Junio 2016

Rank	Site	System	Cores	Rmax (TFlop/s)	Rpeak (TFlop/s)	Power (kW)
1	National Supercomputing Center in Wuxi China	Sunway TaihuLight - Sunway MPP, Sunway SW26010 260C 1.45GHz, Sunway NRCP	10,649,600	93,014.6	125,435.9	15,371
2	National Super Computer Center in Guangzhou China	Tianhe-2 (MilkyWay-2) - TH-IVB-FEP Cluster, Intel Xeon E5-2692 12C 2.200GHz, TH Express-2, Intel Xeon Phi 31S1P	3,120,000	33,862.7	54,902.4	17,808
3	DOE/SC/Oak Ridge National Laboratory United States	Titan - Cray XK7, Opteron 6274 16C 2.200GHz, Cray Gemini interconnect, NVIDIA K20x Cray Inc.	560,640	17,590.0	27,112.3	8,809
4	DOE/NNSA/LLNL United States	Sequoia - BlueGene/Q, Power BQC 16C 1.60 GHz, Custom IBM	1,572,864	17,173.2	20,132.7	7,890
5	RIKEN Advanced Institute for Computational Science (AICS) Japan	K computer, SPARC64 VIIIfx 2.0GHz, Tofu interconnect Fujitsu	705,024	10,510.0	11,280.4	12,660
6	DOE/SC/Argonne National Laboratory United States	Mira - BlueGene/Q, Power BQC 16C 1.60GHz, Custom IBM	786,432	8,586.6	10,066.3	3,945
7	DOE/NNSA/LANL/SNL United States	Trinity - Cray XC40, Xeon E5-2698v3 16C 2.3GHz, Aries interconnect Cray Inc.	301,056	8,100.9	11,078.9	
8	Swiss National Supercomputing Centre (CSCS) Switzerland	Piz Daint - Cray XC30, Xeon E5-2670 8C 2.600GHz, Aries interconnect, NVIDIA K20x Cray Inc.	115,984	6,271.0	7,788.9	2,325
9	HLRS - Höchstleistungsrechenzentrum Stuttgart Germany	Hazel Hen - Cray XC40, Xeon E5-2680v3 12C 2.5GHz, Aries interconnect Cray Inc.	185,088	5,848.2	7,403.5	
10	King Abdullah University of Science and Technology Saudi Arabia	Shaheen II - Cray XC40, Xeon E5-2698v3 16C 2.3GHz, Aries interconnect Cray Inc.	196,608	5,537.0	7,235.2	2,834



Motivación

Top 500
Junio 2025

Rank	System	Cores	Rmax (PFlop/s)	Rpeak (PFlop/s)	Power (kW)
1	El Capitan - HPE Cray EX255a, AMD 4th Gen EPYC 24C 1.8GHz, AMD Instinct MI300A, Slingshot-11, TOSS, HPE DOE/NNSA/LLNL United States	11,039,616	1,742.00	2,746.38	29,581
2	Frontier - HPE Cray EX235a, AMD Optimized 3rd Generation EPYC 64C 2GHz, AMD Instinct MI250X, Slingshot-11, HPE Cray OS, HPE DOE/SC/Oak Ridge National Laboratory United States	9,066,176	1,353.00	2,055.72	24,607
3	Aurora - HPE Cray EX - Intel Exascale Compute Blade, Xeon CPU Max 9470 52C 2.4GHz, Intel Data Center GPU Max, Slingshot-11, Intel DOE/SC/Argonne National Laboratory United States	9,264,128	1,012.00	1,980.01	38,698
4	JUPITER Booster - BullSequana XH3000, GH Superchip 72C 3GHz, NVIDIA GH200 Superchip, Quad-Rail NVIDIA InfiniBand NDR200, RedHat Enterprise Linux, EVIDEN EuroHPC/FZJ Germany	4,801,344	793.40	930.00	13,088
5	Eagle - Microsoft NDv5, Xeon Platinum 8480C 48C 2GHz, NVIDIA H100, NVIDIA Infiniband NDR, Microsoft Azure Microsoft Azure United States	2,073,600	561.20	846.84	

<https://top500.org/lists/top500/2025/06/>

Motivación

Top 500
Junio 2025

6	HPC6 - HPE Cray EX235a, AMD Optimized 3rd Generation EPYC 64C 2GHz, AMD Instinct MI250X, Slingshot-11, RHEL 8.9, HPE Eni S.p.A. Italy	3,143,520	477.90	606.97	8,461
7	Supercomputer Fugaku - Supercomputer Fugaku, A64FX 48C 2.2GHz, Tofu interconnect D, Fujitsu RIKEN Center for Computational Science Japan	7,630,848	442.01	537.21	29,899
8	Alps - HPE Cray EX254n, NVIDIA Grace 72C 3.1GHz, NVIDIA GH200 Superchip, Slingshot-11, HPE Cray OS, HPE Swiss National Supercomputing Centre (CSCS) Switzerland	2,121,600	434.90	574.84	7,124
9	LUMI - HPE Cray EX235a, AMD Optimized 3rd Generation EPYC 64C 2GHz, AMD Instinct MI250X, Slingshot-11, HPE EuroHPC/CSC Finland	2,752,704	379.70	531.51	7,107
10	Leonardo - BullSequana XH2000, Xeon Platinum 8358 32C 2.6GHz, NVIDIA A100 SXM4 64 GB, Quad-rail NVIDIA HDR100 Infiniband, EVIDEN EuroHPC/CINECA Italy	1,824,768	241.20	306.31	7,484

<https://top500.org/lists/top500/2025/06/>

Motivación

- Desde 2012 uno de los objetivos del diseño ha sido la reducción del consumo energético.
- Se busca lograr aumentar la relación desempeño-consumo, es decir los Gflops efectivamente computados por Watt.
- Green 500:
 - Las 500 computadoras más eficientes energéticamente del mundo.
 - Se elabora usando las 500 computadoras que aparecen en el top 500.
 - <http://www.green500.org/>
 - Revisemos los 10 primeros puestos

Motivación

Green
Top 500
Junio 2016

Green500 Rank	MFLOPS/W	Site*	Computer*	Total Power (kW)
1	6,673.84	Advanced Center for Computing and Communication, RIKEN	Shoubu - ZettaScaler-1.6, Xeon E5-2618Lv3 8C 2.3GHz, Infiniband FDR, PEZY-SCnp	149.99
2	6,195.22	Computational Astrophysics Laboratory, RIKEN	Satsuki - ZettaScaler-1.6, Xeon E5-2618Lv3 8C 2.3GHz, Infiniband FDR, PEZY-SCnp	46.89
3	6,051.30	National Supercomputing Center in Wuxi	Sunway TaihuLight - Sunway MPP, Sunway SW26010 260C 1.45GHz, Sunway	15,371.00
4	5,272.09	GSI Helmholtz Center	ASUS ESC4000 FDR/G2S, Intel Xeon E5-2690v2 10C 3GHz, Infiniband FDR, AMD FirePro S9150	57.15
5	4,778.46	Institute of Modern Physics (IMP), Chinese Academy of Sciences	Sugon Cluster W7801, Xeon E5-2640v3 8C 2.6GHz, Infiniband QDR, NVIDIA Tesla K80	65.00
6	4,112.11	Stanford Research Computing Center	XStream - Cray CS-Storm, Intel Xeon E5-2680v2 10C 2.8GHz, Infiniband FDR, Nvidia K80	190.00
7	3,775.45	Internet Service (B)	Inspur TS10000 HPC Server, Intel Xeon E5-2620v2 6C 2.1GHz, 10G Ethernet, NVIDIA Tesla K40	110.00
8	3,775.45	Internet Service (B)	Inspur TS10000 HPC Server, Intel Xeon E5-2620v2 6C 2.1GHz, 10G Ethernet, NVIDIA Tesla K40	110.00
9	3,775.45	Internet Service (B)	Inspur TS10000 HPC Server, Intel Xeon E5-2620v2 6C 2.1GHz, 10G Ethernet, NVIDIA Tesla K40	110.00
10	3,775.45	Internet Service (B)	Inspur TS10000 HPC Server, Intel Xeon E5-2620v2 6C 2.1GHz, 10G Ethernet, NVIDIA Tesla K40	110.00

Motivación

Green
Top 500
Junio 2025

Rank	TOP500 Rank	System	Nodes	Rmax (PFlop/s)	Power (kW)	Energy Efficiency (GFlops/watts)
1	259	JEDI - BullSequana XH3000, Grace Hopper Superchip 72C 3GHz, NVIDIA GH200 Superchip, Quad-Rail NVIDIA InfiniBand NDR200, ParTec/EVIDEN EuroHPC/FZJ Germany	19,584	4.50	67	72.733
2	148	ROMEO-2025 - BullSequana XH3000, Grace Hopper Superchip 72C 3GHz, NVIDIA GH200 Superchip, Quad-Rail NVIDIA InfiniBand NDR200, Red Hat Enterprise Linux, EVIDEN ROMEO HPC Center - Champagne-Ardenne France	47,328	9.86	140	70.912
3	484	Adastra 2 - HPE Cray EX255a, AMD 4th Gen EPYC 24C 1.8GHz, AMD Instinct MI300A, Slingshot-11, RHEL, HPE Grand Equipement National de Calcul Intensif - Centre Informatique National de l'Enseignement Supérieur (CENCI CINES) France	16,128	2.53	37	69.098
4	183	Isambard-AI phase 1 - HPE Cray EX254n, NVIDIA Grace 72C 3.1GHz, NVIDIA GH200 Superchip, Slingshot-11, HPE University of Bristol United Kingdom	34,272	7.42	117	68.935
5	255	Otus (GPU only) - ThinkSystem SD665-N V3, AMD EPYC 9655 96C 2.6GHz, NVIDIA H100 SXM5 80GB, Infiniband NDR, Rocky Linux 9.4, Lenovo Universitaet Paderborn - PC2 Germany	19,440	4.66		68.177

<https://top500.org/lists/green500/2025/06/>

Motivación

6	66	Capella - Lenovo ThinkSystem SD665-N V3, AMD EPYC 9334 32C 2.7GHz, Nvidia H100 SXM5 94Gb, Infiniband NDR200, AlmaLinux 9.4, MEGWARE TU Dresden, ZIH Germany	85,248	24.06	445	68.053
7	304	SSC-24 Energy Module - HPE Cray XD670, Xeon Gold 6430 32C 2.1GHz, NVIDIA H100 SXM5 80GB, Infiniband NDR400, RHEL 9.2, HPE Samsung Electronics South Korea	11,200	3.82	69	67.251
8	85	Helios GPU - HPE Cray EX254n, NVIDIA Grace 72C 3.1GHz, NVIDIA GH200 Superchip, Slingshot-11, HPE Cyfronet Poland	89,760	19.14	317	66.948
9	399	AMD Ouranos - BullSequana XH3000, AMD 4th Gen EPYC 24C 1.8GHz, AMD Instinct MI300A, Infiniband NDR200, RedHat Enterprise Linux, EVIDEN Atos France	16,632	2.99	48	66.464
10	412	Henri - ThinkSystem SR670 V2, Intel Xeon Platinum 8362 32C 2.8GHz, NVIDIA H100 80GB PCIe, Infiniband HDR, Lenovo Flatiron Institute United States	8,288	2.88	44	65.396

Green
Top 500
Junio 2025

<https://top500.org/lists/green500/2025/06/>

Motivación

- Aplicaciones novedosas e interesantes:
 - Deep Learning para tratamiento del cancer
<https://news.developer.nvidia.com/improving-cancer-treatment-with-gpu-accelerated-supercomputers/>
 - Procesamiento de imágenes en tomógrafo
<https://www.lanacion.com.ar/2157971-que-tiene-de-singular-el-primer-tomografo-disenado-en-la-argentina>

Curso de GPGPU

Curso de GPGPU

- **Nombre de la asignatura: Programación masivamente paralela en procesadores gráficos (GPUs)**
- **Créditos: 10**
- **Materia: Arquitectura, Sistemas Operativos y Redes de Computadoras.**
- **Previaturas:**
 - **Programación 2 (Examen).**
 - **Una de las tres siguientes opciones:**
 - **Examen de Arquitectura de Computadoras**
 - **Examen de Sistemas Operativos**
 - **Curso de Arquitectura de Computadoras y Curso de Sistemas Operativos**

Curso de GPGPU

- **Objetivo de la asignatura:**
 - Introducir al estudiante en el uso de los procesadores gráficos para la resolución de problemas de propósito general.
- **Equipo docente:**
 - Pablo Ezzatti , Martín Pedemonte, Ernesto Dufrechou y Manuel Freire.

Curso de GPGPU

- **Forma de evaluación:**
 - Realización de ejercicios durante el curso.
 - Trabajo de laboratorio final.
 - Defensa o prueba escrita.
- **Para aprobar la asignatura se debe aprobar cada una de las instancias de evaluación.**
- **Calificación final:**
 - Ejercicios 40%
 - Laboratorio final 40%
 - Defensa o prueba escrita 20%

Curso de GPGPU

- El curso no tiene cupo.
- Es fundamental que se matriculen al EVA:
<https://eva.fing.edu.uy/course/view.php?id=1076>
- Toda la comunicación de información vinculada al curso se realiza a través del EVA del curso
- Dos clases por semana.

Un poco de historia...

Un poco de historia...



1981 MDA: solo texto



1982 Hercules: pixels





1983 CGA: color




1984 EGA: 16 colores

Un poco de historia...



1987 VGA: último estándar exitoso de IBM



Durante la década del '90 se continúan mejorando las resoluciones y la cantidad de colores.

Un poco de historia...

- Sin embargo, el avance más importante de la década del '90 es el surgimiento de las primeras tarjetas con capacidad de reproducir efectos en 2D/3D:
 - 3dfx Interactive (1996-2000):
 - Línea Voodoo
 - ATI (1995-2004):
 - Línea Rage
 - Nvidia (1998-2005):
 - Líneas TNT y GeForce



¿Dónde estamos hoy?

Videos en tiempo actuales:

<https://www.youtube.com/watch?v=KJRZTkttgLw>

<https://www.youtube.com/watch?v=AV279wThmVU>

<https://www.youtube.com/watch?v=tjf-1BxpR9c>

El pipeline gráfico

El pipeline gráfico


- Las operaciones para visualizar imágenes en pantalla se agrupan en un proceso generalmente conocido como pipeline gráfico.
- Típicamente se deben desplegar imágenes que son proyecciones de escenas tridimensionales en una pantalla bidimensional.
- Durante la década del 90 se diseñan tarjetas gráficas que van incorporando etapas del pipeline gráfico, con el fin de aliviar a la CPU.

El pipeline gráfico

- En 1999, Nvidia lanza al mercado la GeForce 256 que es considerada la primera GPU (Graphics Processing Unit).
- La GeForce 256 es la primera tarjeta de video consumer-level que implementa el pipeline gráfico completo.
- El pipeline gráfico ha sido definido con diferente nivel de detalle por diversos autores.
- A continuación presentaremos el pipeline gráfico basado en la descripción de Kirk y Hwu (Programming Massively Parallel Processors: A Hands-on Approach).

El pipeline gráfico


- La primera etapa del pipeline se encarga de recibir las imágenes de la CPU en algún formato manejable.
- Dicho formato es una colección de primitivas.
- Las primitivas suelen ser triángulos ya que son los polígonos más simples y permiten un manejo eficiente.



El pipeline gráfico

- **Vertex control:**


- Cada triángulo se transforma de acuerdo a su posición y orientación respecto al punto de vista.
- Cada uno de los vértices del triángulo se transforma a otra posición.
- Se eliminan los vértices no visibles.



El pipeline gráfico


- **VS/T & L:**

- Sombreado de vértices, transformaciones e iluminación.
- Se transforman los vértices, asignando propiedades a los vértices visibles como son: colores, normales, tangentes, texturas, etc.
- Esta etapa es realizada por los vertex shaders.
- Es una etapa computacionalmente costosa.



El pipeline gráfico


- **Triangle setup:**
 - Realiza cálculos para las aristas, interpolando colores y otros valores de los vértices.
- **Raster:**
 - Determina para cada triángulo que píxeles lo integran.
 - Por cada píxel se interpola, a partir de los vértices, los valores necesarios para sombrear los píxeles, evaluar la inclusión de colores y determinar la posición de la textura que será pintada en el pixel.



El pipeline gráfico

- **Shader (sombreado):**

- En esta etapa se ejecutan los efectos que permiten renderizar imágenes en forma más realista.
- Se determina el color final de cada píxel.
- Se utilizan técnicas como la interpolación de colores entre vértices, el mapeo de textura, la iluminación por píxel.
- Esta etapa es computada por los pixel shaders.
- Esta etapa es costosa computacionalmente.




El pipeline gráfico

- **ROP (Raster OPeration):**

- Se aplican restricciones finales sobre cada píxel.
- Por ejemplo: mezcla de colores de triángulos superpuestos para mejorar los efectos de transparencias y antialiasing.
- Se determinan los objetos visibles para un punto de vista dado y se descartan los píxeles ocultos.


- **FBI (Frame Buffer Interface):**

- Lee y escribe en el buffer de imagen.



El pipeline gráfico

Ejemplo: la arquitectura de la GeForce 7800 (pre-CUDA)




¿Por qué una arquitectura unificada?

¿Por qué una arquitectura unificada?

Why unify?



**Heavy Geometry
Workload Perf = 4**



**Heavy Pixel
Workload Perf = 8**

¿Por qué una arquitectura unificada?

Why unify?

Unified Shader




**Heavy Geometry
Workload Perf =12**

Unified Shader




**Heavy Pixel
Workload Perf = 12**

¿Por qué una arquitectura unificada?




¿Por qué una arquitectura unificada?



¿Por qué una arquitectura unificada?

La arquitectura del chip G80 (GeForce 8800)



¿Por qué una arquitectura unificada?

¿Y por qué siempre terminamos acá?: Arquitectura Ampere (2021)



Tarjetas programables

Tarjetas programables

- En los últimos 20 años existe un auge de la utilización de GPUs para el cómputo de problemas de propósito general.
- Este crecimiento se basa fundamentalmente en:
 - La arquitectura es intrínsecamente paralela, en contraste con la arquitectura serial de las CPUs.
 - La industria de los videojuegos presiona a los fabricantes de tarjetas gráficas para aumentar las capacidades de procesamiento gráfico para que los juegos sean más realistas y más rápidos.
 - La industria de la inteligencia artificial también presiona
 - El surgimiento de lenguajes de programación de propósito general para GPUs.

Tarjetas programables

- Las tarjetas de video viejas tenían un pipeline gráfico fijo.
- Las operaciones ejecutadas y el orden en que se aplicaban sobre los datos estaba preconfigurado.
- Originalmente, las GPUs proveían operaciones propias para la transformación e iluminación (vertex shaders) en los vértices, y para determinar el color final de los píxeles (pixel shaders).

Tarjetas programables

- **1999-2006: se produce una mejora significativa en las capacidades de programación de las GPUs.**
- **Algunos hitos son:**
 - **GeForce 3 (2001): primera GPU que ejecutaba vertex shaders programados.**
 - **ATI Radeon 9700 (2002): introdujo la aritmética de punto flotante de 24 bits.**
 - **GeForce FX (2002-2003): introdujo el trabajo con aritmética de punto flotante de 32 bits.**
 - **Xbox 360 (2005): primera arquitectura unificada de procesadores para el pipeline gráfico. Una sola clase de procesadores computa las distintas secciones del pipeline.**

Tarjetas programables

- En un principio, el avance en el hardware no fue acompañado por un avance en el software de manejo de las GPUs.
- Inicialmente la programación de las GPUs se realizaba mediante llamados a servicios de interrupción de la BIOS.
- Posteriormente, se comenzaron a desarrollar los shaders en el lenguaje ensamblador específico de cada modelo.
- Esto implicaba la existencia de varios lenguajes y baja portabilidad de los programas.
- Otra alternativa era utilizar las APIs gráficas como OpenGL y DirectX.

Tarjetas programables

- Evidentemente esto representaba una limitación para el desarrollo de aplicaciones.
- Para solucionarlo se desarrollaron diferentes lenguajes de programación de más alto nivel que funcionaran sobre los modelos de GPU existentes.
- Algunos adoptan como modelo el considerar a la GPU como un stream processor.
- Sin embargo, cada herramienta seguía siendo muy dependiente de la arquitectura de la GPU, el modelo, etc.

CUDA

CUDA


- **En el año 2007, Nvidia presenta CUDA (Compute Unified Device Architecture).**
- **Produjo un cambio radical en la arquitectura de las GPUs de Nvidia:**
 - **arquitectura unificada sin distinción entre procesadores de píxeles y vértices.**
- **Produjo un cambio radical en el software para desarrollo de aplicaciones en las GPUs de Nvidia.**
- **Es el mojón más importante desde el nacimiento de la programación de propósito general en GPUs (GPGPU).**
- **Masificó la GPGPU, ya que dejó de ser un juego para eruditos y se transformó en una alternativa a la alcance de cualquier desarrollador.**

CUDA

- **Pero, ¿qué es CUDA?**
- **CUDA:**
 - Es una arquitectura de computación paralela para el cómputo de problemas de propósito general diseñada por Nvidia.
 - Está enfocada al cálculo masivamente paralelo y las capacidades de procesamiento que brinda las tarjetas gráficas de Nvidia.
 - Permite programar el dispositivo a través de extensiones de lenguajes de programación estándar (C y Fortran)
 - Está disponible para las tarjetas gráficas GeForce de la serie 8 en adelante.

CUDA

- Se compone de una pila de capas de software que incluye bibliotecas, el CUDA Runtime y el CUDA Driver.



CUDA

- **Bibliotecas de CUDA:**
 - Bibliotecas de alto nivel
 - CUFFT para el cálculo de Transformadas de Fourier.
 - CUBLAS es una implementación de BLAS (Basic Linear Algebra Subprograms) en GPU.
- **CUDA Driver:**
 - Es un controlador de hardware.
 - Está dedicado a la transferencia de datos entre la CPU y la GPU.
- **CUDA Runtime:**
 - Provee una interfaz de programación de aplicaciones (API).
 - Provee un conjunto de instrucciones accesible a través de lenguajes de alto nivel como son Fortran y C.

CUDA

- **Al programar en CUDA, la GPU se ve como un dispositivo de cómputo capaz de ejecutar un número muy elevado de hilos en paralelo.**
- **La GPU funciona como un coprocesador de la CPU (host).**
- **A la GPU se le suele llamar dispositivo (device).**

CUDA

- Si una parte de una aplicación se ejecuta muchas veces pero en forma independiente sobre diferentes datos, puede ser aislada en una función que se ejecutará en el dispositivo mediante muchos hilos de ejecución en forma concurrente.
- La función se compila usando el conjunto de instrucciones del dispositivo.
- El programa resultante, llamado núcleo (kernel), se descarga en el dispositivo para su ejecución.


CUDA

- El curso se centra en CUDA y las arquitecturas de Nvidia.
- Se comentarán algunos aspectos de otros lenguajes que siguen una filosofía similar como OpenCL.
- No se entrará en detalles de las arquitecturas de AMD/ATI ya que presentan características distintas.

Comparación de la performance CPU vs GPU



Comparación de la performance CPU vs GPU

Pico teórico de performance en GFLOP/s




Comparación de la performance CPU vs GPU

- La arquitectura de las GPUs es radicalmente distinta a la de una CPU.




Comparación de la performance CPU vs GPU

- En una CPU tradicional gran parte de los transistores están dedicados a realizar otro tipo de tareas:
 - Predicción de branches.
 - Prefetch de memoria.
 - Ejecución fuera de orden.
 - Caché de datos.
- En las GPUs hay más transistores dedicados al cálculo.



Comparación de la performance CPU vs GPU

Pico teórico de performance en GFLOP/s



Comparación de la performance CPU vs GPU

- **¿Cómo se calcula el pico teórico de performance?**
 - **FLOPS = #cores * Frecuencia * Ops**
 - **FLOPS:** operaciones de punto flotante por segundo
 - **#cores:** número de cores
 - **Frecuencia:** frecuencia del core
 - **Ops:** operaciones de punto flotante por core y por ciclo.
- **La cantidad de operaciones de punto flotante por core depende de:**
 - Si es una CPU o una GPU.
 - Si se trabaja en simple o en doble precisión.

Comparación de la performance CPU vs GPU


- **Un ejemplo de CPU: Westmere**
 - 8 ops de precisión simple por ciclo por core.
 - 4 ops de precisión doble por ciclo por core.
 - Gulftown/Westmere-EP: 6 Cores a 3.46 GHz (U\$S 1663)
 - Pico en simple = $6 * 3.46 * 8 = 166.08$ GFLOPS
 - Pico en doble = $6 * 3.46 * 4 = 83.04$ GFLOPS
 - El hyperthreading no mejora la performance

Comparación de la performance CPU vs GPU

- **Un ejemplo de GPU: GeForce GTX 480**
 - 2 ops de precisión simple por ciclo por core.
 - 1/2 ops de precisión doble por ciclo por core.
 - GeForce GTX480: 480 CUDA Cores a 1401 MHz (U\$S 500)
 - Pico en simple = $480 * 1401 * 2 = 1344.96$ GFLOPS
 - Pico en doble = $480 * 1401 * 1/2 = 336.24$ GFLOPS
- **Algunos comentarios:**
 - Ojo! Un mega y un giga son 1000 y no 1024.
 - Las GeForce suelen tener peor desempeño en doble precisión.
 - Las Tesla hacen más operaciones por ciclo pero son más caras.

Comparación de la performance CPU vs GPU

Pico teórico de tasa de transferencia de memoria en GB/s



Comparación de la performance CPU vs GPU

- ¿Cómo se calcula el pico teórico de tasa de transferencia de memoria?
 - Tasa de transferencia = ancho del interfaz de memoria * frecuencia de la memoria.
- Un ejemplo de CPU: Westmere
 - ancho del interfaz de memoria = 64 bits = 8 bytes
 - la memoria es 3×DDR3-1333 que puede leer o escribir dos palabras de datos por vez y cuatro veces por ciclo de reloj.
 - frecuencia de la memoria = 166.66 Mhz
 - Tasa de transferencia = $3 * 2 * 4 * 8 * 166.66 = 31.99 \text{ GB/s}$

Comparación de la performance CPU vs GPU

- **Un ejemplo de GPU: GeForce GTX 480**
 - ancho del interfaz de memoria = 384 bits = 48 bytes
 - frecuencia de la memoria = 1848 Mhz
 - la memoria es GDDR5 que puede leer o escribir dos palabras de datos por ciclo de reloj.
 - Tasa de transferencia = $48 * 1848 * 2 = 177.40 \text{ GB/s}$

Comparación de la performance CPU vs GPU

- La otra cara de la moneda:
 - Estudio comparativo realizado por Intel entre un i7 de 4 cores y una GTX280 sobre varios problemas.
 - La gráfica muestra la performance relativa entre la GTX280 y el i7.




Figure 1: Comparison between Core i7 and GTX280 Performance.