


Programación masivamente paralela en procesadores gráficos (GPUs)

E. Dufrechou , M. Freire, P. Ezzatti y M. Pedemonte



Clase 9

Programación CUDA IV

Contenido

- Transferencias a memoria

Transferencias a Memoria

Transferencias a memoria

Memoria no paginable

- **cudaHostAlloc()**
 - Mayor ancho de banda
 - Posibilidad de mapear memoria del host en el device.
 - Es un recurso limitado
 - Evita copia de paginable a no paginable.
- **Optimización de transferencias**
 - Agrupar transferencias
 - Evitar transferencia de poca memoria

Transferencias a memoria

Transferencias asincrónicas

- Utilizan streams (no entraremos en detalles)

```
cudaMallocHost( (void **)& hostPtr, NUM_STREAMS * size) ;  
  
cudaStreamCreate( &stream [ i ] );  
  
cudaMemcpyAsync ( inputDevPtr + i * size,  
                  hostPtr + i * size, size,  
                  cudaMemcpyHostToDevice, stream [ i ] );
```

- Permiten solapar cálculos con transferencias.
- Ojo! Ahora las transferencias no sincronizan!