

Uso de IA Generativa:

En este práctico **NO se permite** el uso de estas herramientas.

Práctico 3 - Memoria compartida y programación a nivel de warp

El objetivo de este práctico es poner en práctica conceptos relacionados con el acceso a la memoria compartida y operaciones de shuffle.

Los tiempos de ejecución deben tomarse como el promedio de 10 ejecuciones (presentando únicamente el promedio y desviación estándar en el informe). Para obtener este dato fácilmente es conveniente utilizar la herramienta NsightSystems de la siguiente forma:

```
sbatch lanzar.sh nsys profile --stats true ./programa
```

Ejercicio 1

Memoria compartida

En este ejercicio se adopta una estrategia diferente a la utilizada en el Ejercicio 3 del práctico anterior para mejorar el acceso coalesced en las operaciones de lectura y escritura en memoria global del kernel de transposición de matrices. La idea consiste en utilizar una copia en memoria compartida del tile a trasponer, de modo que los accesos que resultarían ineficientes en memoria global se realicen en memoria compartida.

1. Configure una grilla de bloques de tamaño 32×32 . Reserve un espacio en memoria compartida de tamaño igual al del bloque y utilice este espacio para evitar los accesos no-coalesced a la memoria global (es decir, realizar los accesos que serían no-coalesced sobre este espacio en lugar de la memoria global). Compare el desempeño del kernel con las versiones del práctico anterior.
2. Analice el patrón de lectura y escritura en la memoria compartida y determine cuando ocurren conflictos de bancos. Solucione los conflictos de bancos agregando una columna *dummy* al final del tile de memoria compartida. Compruebe el efecto de esta modificación comparando los tiempos de ejecución con la parte anterior y explique por qué esto soluciona los conflictos de bancos.

Ejercicio 2

Warp shuffle

Partiremos de un arreglo de enteros, de tamaño múltiplo de 32, en memoria global, en el que algunos son positivos y otros negativos. Se trabajará con una grilla unidimensional y se mapeará cada hilo a un elemento del arreglo. Para cada segmento de 32 enteros consecutivos se debe hacer lo siguiente: *Los elementos negativos del segmento deben ser reemplazados por la suma de estos más el máximo de los elementos positivos del segmento.*

Ejemplo: $func([1\ 7\ 2\ -5\ -9\ -3\ 11\ 12\ 11]) = [1\ 7\ 2\ -2\ -2\ -2\ 11\ 12\ 11]$

1. Resuelva el ejercicio utilizando la memoria compartida (sin primitivas a nivel de warp).
2. Resuelva el ejercicio utilizando primitivas a nivel de warp. Además de las primitivas vistas en el teórico, será útil la primitiva `__ballot_sync`. Esta función recibe un valor booleano por cada hilo del warp y devuelve una máscara de 32 bits, donde el bit i está en 1 si el valor para el lane i es verdadero y 0 en caso contrario.

Entrega

- Se debe entregar un informe en PDF con la solución de los ejercicios que contenga, **como máximo, 4 páginas** (sin contar índices, carátulas, figuras, etc.).
- Entregar un archivo comprimido con el código fuente y los scripts necesarios para ejecutar un caso de prueba de forma sencilla.